基于组合范畴语法的中文语义分析

章晔
2016/5/2

目录

一、组合范畴语法

组合范畴语法（Combinatory Categorial Grammar）是一种将句法（syntax）和语义（semantics）紧密结合的语言学表示，可以用来模拟广泛的语言现象。用于语义分析的组合范畴语法主要包含词典和组合规则。

1.1 词典

词典中每个词条以如下形式表示：

words :- X : h

其中 words 表示自然语言中的短语或句子，X 表示该词组的句法成分，h 是一个逻辑表达式，表示该短语对应的语义。

句法成分中，S 表示句子，NP 表示名词成分。在本项目中，所有的句法成分都用 S 和 NP 的组合表示。比如 S\NP 表示该短语可以与前面的名词成分 NP 构成一个句子 S，S/NP 表示该短语可以与后面的名字成分 NP 构成一个句子 S。S|NP 表示 S\NP 或者 S/NP 均可，例如 S/(S|NP)后面接 S/NP、S\NP 或 S|NP 都可以构成一个句子 S。

逻辑表达式用 Lambda Calculus 表示。

词条示例：

西单 :- NP : 西单:s

附近有 :- S\NP/NP : λxλy.zone(x, y)

1.2 语法规则

组合范畴语法根据一些组合规则，将相邻的短语连接起来，形成组合的句法成分和语义。本项目中用到的是四条基本规则：

X/Y:f Y/Z:g => X/Z:λx.f(g(x))	forward composition (>B)
X/Y:f Y:g => X:f(g)	forward apply (>)
Y\Z:g X\Y:f => X\Z:λx.f(g(x))	backward composition (<B)
Y:g X\Y:f => X:f(g)	backward apply (<)

比如对于“五道口有全聚德”这句话，由三个短语“五道口”“有”“全聚德”构成，对相邻的短语根据规则进行组合，最后得到整个句子的句法成分是 S，表示这是一句完整的语句，并且解析出这句话的语义。

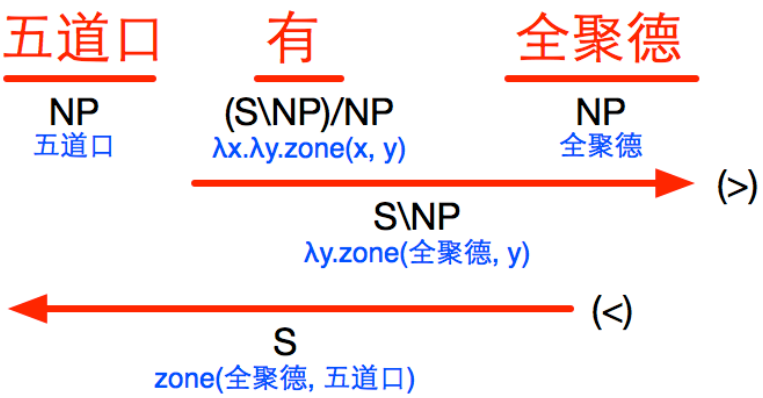

二、逻辑表达式

语义分析（Semantic Parsing）是将自然语句转化成逻辑表达式来表示语义。本项目逻辑表达式使用 Lambda Calculus。

2.1 Lambda Calculus

Lambda Calculus 有三种类型：t 表示真值类型，e 表示实体类型，i 表示数字。Lambda Calculus 中也有函数，即表示实体之间的关系。函数类型由输入类型和返回类型组成，比如 price(x)的类型是<e, i>，输入 x 是实体，返回值是数字；restaurant(x)的类型是<e, t>，输入是实体，返回值是真值。

其中实体 e，还可以根据特定领域设定子类型。

Lambda Calculus 表达式有以下几种部分构成：

常量，又分为名词常量和关系常量。名词常量，比如“中关村”“火锅”这些地名或者标签，名词常量都是实体，需要标明实体类型。关系常量，即根据需要自定义的关系函数，比如商圈，人均价格。关系常量也需要标明函数类型。

逻辑联结词，即与、或、非。

Lambda 项，表示使得后面表达式为真的项，比如 λx.zone(x, 五道口)表示存在(x, zone, 五道口)这种关系的实体。

逻辑表达式示例：

λx.restaurant(x)∧zone(x, 五道口)∧hasCuisine(x, 麻辣小龙虾)，表示五道口卖麻辣小龙虾的餐厅。

三、模型设计

利用组合范畴语法进行语义分析的过程如下图所示。

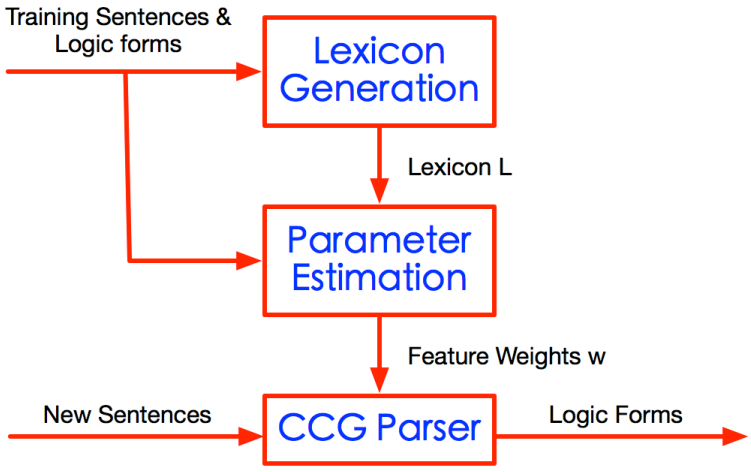

利用训练数据，即自然语句和对应的逻辑表达式，生成词典，并利用词典和训练数据进行参数估计，进行数轮迭代，最终得到一个组合范畴语法的语义分析器，包含一个词典和特征权重。

对于新的句子，通过语义分析器分析，可以得到对应的逻辑表达式。

3.1 对数线性模型

给定一个词典 Λ 和语法规则，对一个句子的语义分析可能产生很多结果。我们使用对数线性模型来选择可能性最高的结果。

给出一个句子 x，对这个句子进行语义分析，经过解析过程 y 得到逻辑表达式 z 的概率为：

$$P(y,z|x;\theta,\Lambda)=\frac{e^{\theta\cdot\phi(x,y,z)}}{\sum_{(y',z')}e^{\theta\cdot\phi(x,y',z')}}$$

其中，φ 是特征向量，θ 是参数向量。

对于句子 x，找出可能性最高的逻辑表达式，即：

$$f(x) = \arg\max_z p(z|x;\theta,\Lambda)$$

其中，逻辑表达式 z 的概率为所有得到此表达式的分析过程的概率之和：

$$p(z|x;\theta,\Lambda) = \sum_y p(y,z|x;\theta,\Lambda)$$

3.2 特征

给出句子 x，经过语义分析过程 y 得到逻辑表达式 z，特征向量为使用了词典中哪些词条。参数向量为词典中每一个词条的权重。

3.3 参数估计

我们使用随机梯度下降法进行参数估计，对每个样本更新一次。

给定 n 对训练数据(x_i, z_i)，i=1…n。每轮迭代，对于每对训练数据，都更新参数。

每个样本的最大化目标函数为：

$$O_i = \log P(z_i|x_i;\theta,\Lambda)$$

对 θ_j 求偏导计算梯度 Δ，计算公式为：

$$\frac{\partial O_i}{\partial \theta_j} = E_{p(y|x_i,z_i;\theta,\Lambda)}[\phi_j(x_i,y,z_i)] - E_{p(y,z|x_i;\theta,\Lambda)}[\phi_j(x_i,y,z)]$$

更新参数：

$$\theta=\theta+\alpha\Delta$$

α 为学习速率，随迭代增加而减小。

四、词典生成

首先，初始化词典。

每一轮迭代中，对于每一条样本的自然语句，根据当前词典进行语义分析，得到当前得分最高的一个解析树，从这条解析树拆分出新的词条加入词典，然后更新参数。

最终得到一个词典和词典中每个词条的权重。

Initialization:

- Set $\Lambda = \{x_i \vdash S : z_i\}$ for all $i = 1 \ldots n$.
- Set $\Lambda = \Lambda \cup \Lambda_{NP}$
- Initialize θ using coocurrence statistics, as described in Section 7.

Algorithm:

For $t = 1 \ldots T, i = 1 \ldots n$:

Step 1: (Update Lexicon)

- Let $y^* = \arg\max_y p(y|x_i, z_i; \theta, \Lambda)$
- Set $\Lambda = \Lambda \cup \text{NEW-LEX}(y^*)$ and expand the parameter vector θ to contain entries for the new lexical items, as described in Section 7.

Step 2: (Update Parameters)

- Let $\gamma = \frac{\alpha_0}{1+c \times k}$ where $k = i + t \times n$.
- Let $\Delta = E_{p(y|x_i,z_i;\theta,\Lambda)}[\phi(x_i, y, z_i)] - E_{p(y,z|x_i;\theta,\Lambda)}[\phi(x_i, y, z)]$
- Set $\theta = \theta + \gamma\Delta$

Output: Lexicon Λ and parameters θ.

4.1 词典初始化

将训练数据中每一对样本<x_i, z_i>以词条的形式加入词典：

x_i :- S : z_i

然后，将固有名词加入词典，例如：

五道口 :- NP : 五道口:s

全聚德 :- NP : 全聚德:r

这些名词词条将有助于句子中名词实体的识别。

初始化词典中的词条权重初始值都为 10。

由于中文不像英语一样有分词，需要对中文进行分词，将一句话或短语变成一串 token，以便后面进行拆分。

4.2 新词条生成

训练过程中，每轮迭代，对于每一个样本，根据已有词典，对自然语句 x 进行语义分析，产生当前得分最高的一个解析树 y*。

y*中的叶节点即语义分析过程中用到的词条，而非叶结点是过程中产生的新词条。将非叶结点加入词典，并考虑其他可能产生此节点的解析：对非叶非根结点进行拆分，将得到的新词条也加入词典。

以下图“中关村附近的餐厅”一种解析树为例，利用“中关村”、“附近的”和“餐厅”三个词条，解析得到逻辑表达式。

解析树中有非叶非根节点“附近的餐厅”，将此词条加入词典，并对这个词条进行拆分，生成新的词条，这些新的词条都是可以产生“附近的餐厅”的词条，将这些新词条加入词典，并扩展特征向量。

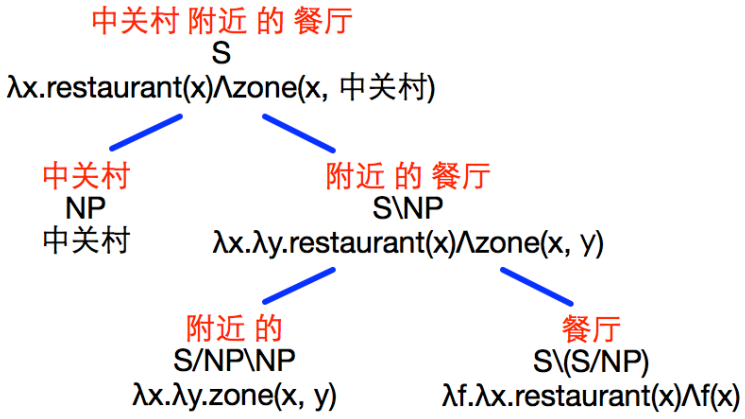

4.3 词条拆分

语句是由短语构成的，组合范畴语法的本质就是根据词典理解每个短语的语义，并将短语组合的句子语义解析出来。

训练数据中的逻辑表达式是对一句完整的语句进行语义标注的，但是为了能够解析更多灵活变化的句子，需要得到每个短语的语义。这就是为什么要对解析树的非叶非根节点进行拆分得到新词条。

4.3.1 拆分限制

将逻辑表达式 h 拆分成 f 和 g，f 和 g 可以根据语法规则这，使得 f(g)=h 或者 λx.f(g(x))=h。

如果不对 f 和 g 加以限制，可能会生成无数种可能性。例如:

h=五道口，f=λx.五道口，g 可以是任何实体或关系，都能使得 f(g)=h。

再例如：

$h=f_1 \wedge f_2 \wedge f_3 \wedge f_4$，h 的任意子条件联结组合都可以分配给 f 或 g。

为了限制拆分可能性的数量，对拆分词条作如下限值：

1、禁止无意义变量

f 和 g 都不能是 λx.e 的形式，其中 e 是与变量 x 无关的逻辑表达式。

2、$h=f_1 \wedge f_2 \wedge f_3 \wedge f_4 \wedge \ldots$时，g 不能包含超过 N 个子条件。本项目中 N 为 4。

3、f 不能是 f= λq.q(A)的形式，其中 q 是 h 中不存在的变量且 q 的输入是非变量。

4.3.2 逻辑表达式句法成分拆分

逻辑表达式 h 的句法成分为 X，即 X:h，将 h 拆分为 f 和 g，f 和 g 的句法成分取决于他们的类型。

以 g 为例，g 的类型为 T(g)，比如 T(五道口)=e，T(λx.zone(x, 五道口))=<e, t>。类型 T 的句法成分为 C(T)：

$$C(T) = \begin{cases} NP & \text{if } T = e \\ S & \text{if } T = t \\ C(T_2)|C(T_1) & \text{when } T = \langle T_1, T_2 \rangle \end{cases}$$

基本类型 e 的句法成分为名词成分 NP，基本类型 t 的句法成分为句子 S，所有其他类型的句法成分可以递归得到。例如 C(<e, t>)=S|NP，C(<e, <e, t>>)=S|NP|NP。

分别对应四条语法规则：

X/Y:f Y/Z:g => X/Z:λx.f(g(x))	forward composition (FC)
X/Y:f Y:g => X:f(g)	forward apply (FA)
Y\Z:g X\Y:f => X\Z:λx.f(g(x))	backward composition (BC)
Y:g X\Y:f => X:f(g)	backward apply (BA)

以四种方式拆分逻辑表达式和句法成分：

FA(X:h) = {(X/Y:f, Y:g) | h=f(g) ∧ Y=C(T(g))

BA(X:h) = {(Y:g, X\Y:f) | h=f(g) ∧ Y=C(T(g))}

FC(X/Y:h) = {(X/W:f, W/Y:g) | h=λx.f(g(x)) ∧ W=C(T(g(x)))}

BC(X\Y:h) = {(W\Y:g, X\W:f) | h=λx.f(g(x)) ∧ W=C(T(g(x)))}

对 A = X:h 所有可能拆分 $S_C(A)$:

$S_C(A)$ = {FA(A) ∪ BA(A) ∪ FC(A) ∪ BC(A)}

4.3.3 词条拆分

将逻辑表达式 h 和句法成分 X 拆分后，对短语（或句子）w 进行拆分。

已分词的 w 由 n 个 token 组成，$w_{0:n}$=<w_0, w_1, …, w_n>。

对词条 $w_{0:n}$:- A 的拆分 $S(w_{0:n}$:- A)：

$S_L(w_{0:n}$:- A) = {($w_{0:i}$:- B, $w_{i+1:n}$:- C) | 0≤i<n ∧ (B,C)∈S_C(A)}

即枚举短语 w 所有拆分方式，与逻辑表达式和句法所有可能拆分方式组合。

五、数据标注

5.1 Lambda Calculus

Lambda Calculus 有三种类型：t 表示真值类型，e 表示实体类型，i 表示数字。其中实体 e，还可以根据特定领域设定子类型。

根据 RDF 知识库的设计方案，实体类型 e 的子类型有：

r，表示餐馆；

c，表示菜品；

s，表示字符串，餐馆和菜品的各种属性值类型都是 s。

Lambda Calculus 中的函数，即表示实体之间的关系，类型由输入类型和返回类型组成，比如 price(x)的类型是<r, i>，输入 x 是餐馆，返回值是数字；restaurant(x)的类型是<r, t>，输入 x 是餐馆，返回值是真值。

Lambda Calculus 表达式有以下几种部分构成：

- 常量，又分为名词常量和关系常量。名词常量，比如“中关村:s”、“火锅:s”、“全聚德:r”，这些地名或者标签，名词常量都是实体，需要标明实体类型。关系常量，即根据需要自定义的关系函数，比如商圈，人均价格。关系常量也需要标明函数类型。
- 逻辑联结词，即与、或、非，用 and，or 和 not 表示。
- Lambda 项，λx.e 表示使得后面表达式 e 为真的 x 。比如
  λx.zone(x, 五道口)表示存在(x, zone, 五道口)这种关系的实体。
  若 x 是实体变量，λx 用 lambda $0 e 表示；
  若 x 是关系变量，比如类型为<e, t>，λx 用 lambda $0 <e, t>表示。
  不过标注数据时不会出现这种情况，一般出现在语义分析器拆分得到的词条中。
  λx.zone(x, 五道口) –> (lambda $0 e (zone:t $0 五道口:s))

5.2 标注方案

Lambda calculus 中的三个基本类型为实体 e、真值 t 和数字 i。
针对餐饮领域，定义子类型：
行政区 dt；
商圈 zn；
餐厅种类 lb；
餐厅名 r；
菜名 c；
字符串 s，表示其他属性值。

用于初始化词典的 np_lexicon 为知识库中提取出的所有的名词常量，名词常量类型都是实体 e，并指定子类型，如行政区 dt，商圈 zn，餐厅种类 lb，以及餐厅名 r 和菜名 c 等。

从 restraunt knowledge 知识库中提取了 85331 家餐厅，63697 道菜，91 个行政区，488 个商圈，100 个餐厅分类的数据，将这些数据加入初始化的词典。

名词常量示例：
五道口 :- NP : 五道口:zn

全聚德 :- NP : 全聚德:r

北京烤鸭 :- NP : 北京烤鸭:c

海淀区 :- NP : 海淀区:dt

知识库中餐厅名有些是带有“（XX 店）”的，提取时，只提取餐厅名字，忽略 XX 店。

根据数据，定义以下 Lambda calculus 关系：

以 (关系名:resType argType1 argType2 … resType) 的形式表示，arg Type 表示参数类型，resType 表示返回类型。

(restaurant:t r t)，表示参数 arg1 是否为餐厅。参数类型是餐厅 r，返回类型是真值 t。

(name:t r s t)，表示参数 arg1 的名字是否为参数 arg2，参数类型为餐厅 r、s，返回类型是 t。

(district:t r dt t)，表示参数 arg1 的行政区是否为参数 arg2，参数类型是餐厅 r、行政区 dt，返回类型是真值 t。

(zone:t r zn t)，表示参数 arg1 的商圈是否为是参数 arg2，参数类型是餐厅 r、商圈 zn，返回类型是真值 t。

(lat:i r i)，表示参数 arg1 的纬度，参数类型是餐厅 r，返回类型是数字 i。

(lng:i r i)，表示参数 arg1 的经度，参数类型是餐厅 r，返回类型是数字 i。

(price:i r i)，表示参数 arg1 的人均价格，参数类型是餐厅 r，返回类型是数字 i。

(address:s r s)，表示参数 arg1 的地址，参数类型是餐厅 r，返回类型是字符串 s。

(tel:s r s)，表示参数 arg1 的电话，参数类型是餐厅 r，返回类型是字符串 s。

(time:s r s)，表示参数 arg1 的营业时间，参数类型是餐厅 r，返回类型是字符串 s。

(label:t r lb t)，表示参数 arg1 的餐厅种类是否为参数 arg2（粤菜、火锅等等），参数类型是餐厅 r，餐厅种类 lb，返回类型是真值 t。

(tasteScore:i r i)，表示参数 arg1 的口味评分，参数类型是餐厅 r，返回类型是真值 t。

(surroundingScore:i r i)，表示参数 arg1 的环境评分，参数类型是餐厅 r，返回类型是真值 t。

(serviceScore:i r i)，表示参数 arg1 的服务评分，参数类型是餐厅 r，返回类型是真值 t。

(hasCuisine:t r c t)，表示参数 arg1 是否有参数 arg2 这道菜，参数类型是餐厅 r，菜品 c，返回类型是真值 t。

(cuisinePrice:i c i)，表示参数 arg1 的价格，参数类型是菜品 c，返回类型是数字 i。

(npeople:t r i t)，表示参数 arg1 能否接纳参数 arg2 人的预订，参数类型是餐厅 r，数字 i，返回类型是数字 i。

将以上定义写入文件，初始化语义分析器时读入。

既然属性值在 RDF 知识库中都是以字符串的形式存储，为何还要定义子类型呢？

一开始我将所有的属性值类型都定义为字符串 s，然后在实验中，我发现这样定义的缺点就是，在根据组合范畴语法组合短语的逻辑表达式时，会出现类型匹配而语义不成立的表达式，比如

zone(x, 烧烤)

实际上，餐厅实体的 zone 这个属性，属性值必须是商圈，而由于定义时，将所有的属性值都看做字符串类型来处理，才会出现这样的错误。

定义了子类型，并指明 lambda calculus 函数参数类型和返回类型后，杜绝了这种错误产生的原因，并且显著提高了准确率。

5.3 数据说明

标注了 621 条餐饮领域的问题，每一个样本为<自然语句，逻辑表达式>对。例如：

西单附近的餐厅

(lambda $0 e (and (restaurant:t $0) (zone:t $0 西单:s)))

五道口有什么比较好吃的日本料理

(lambda $0 e (and (restaurant:t $0) (zone:t $0 五道口:s) (label:t $0 日本料理:s) (> (tasteScore:i $0) 8:i)))

南京大牌档怎么样

(shopScore:i 南京大牌档:r)

南京大牌档有北京烤鸭吃吗

(hasCuisine:t 南京大牌档:r 北京烤鸭:c)

5.4 数据文件

数据及标注方案均在 data 文件夹中：

./data/types: 三元关系 <e, p, e> 中实体 e 类型。

./data/relations: 关系 p。

./data/np_lexicon: 数据中出现的名词实体及其对应逻辑表达式。

./data/train: 训练数据，问题及对应逻辑表达式。